

Sistemas Multi-Agentes Cognitivos Baseados em LLMs para Resolução Colaborativa de Tarefas

Jean Reinhold¹

¹Centro de Desenvolvimento Tecnológico (CDTec)
Universidade Federal de Pelotas (UFPel)
Pelotas – RS – Brasil

jreinhold@inf.ufpel.edu.br

Resumo. *Sistemas multi-agentes baseados em Modelos de Linguagem de Grande Escala (LLMs) têm se destacado como abordagem promissora para a resolução colaborativa de problemas complexos. Este trabalho analisa a arquitetura proposta por Silva et al. (2025), que introduz um sistema multi-agente conversacional cognitivo onde um agente orquestrador distribui dinamicamente tarefas entre agentes especializados equipados com módulos cognitivos. Realizou-se uma análise crítica da arquitetura, identificando seus pontos fortes — como a modularidade e o uso de memória compartilhada — e suas limitações, incluindo desafios de escalabilidade e avaliação. Propõem-se melhorias relacionadas à gestão de memória e aos mecanismos de coordenação entre agentes.*

Abstract. *Multi-agent systems powered by Large Language Models (LLMs) have emerged as a promising approach for collaborative complex problem-solving. This work analyzes the architecture proposed by Silva et al. (2025), which introduces a conversational cognitive multi-agent system where an orchestrator agent dynamically distributes tasks among specialized agents equipped with cognitive modules. A critical analysis of the architecture was conducted, identifying its strengths — such as modularity and shared memory usage — and its limitations, including scalability and evaluation challenges. Improvements related to memory management and inter-agent coordination mechanisms are proposed.*

1. Introdução

Arquiteturas de sistemas multi-agentes baseadas em LLMs têm emergido como abordagem poderosa para a resolução de problemas complexos, permitindo que múltiplos agentes autônomos colaborem em um ambiente compartilhado [Wang et al. 2024]. Apesar dos avanços, desafios significativos persistem: a garantia de comunicação e coordenação fluidas, a manutenção de consistência comportamental e a gestão eficaz de memória em ambientes dinâmicos permanecem como questões em aberto [Sumers et al. 2024].

Silva et al. [Silva et al. 2025] propõem uma arquitetura multi-agente na qual um agente orquestrador distribui dinamicamente tarefas entre agentes cognitivos especializados, denominados *Task-driven Agents*. O sistema utiliza memória compartilhada como mecanismo de coordenação e um paradigma conversacional flexível para comunicação entre agentes.

Este trabalho tem como objetivo analisar criticamente essa arquitetura, identificando seus pontos fortes e limitações, e propor melhorias. A Seção 2 apresenta o referencial teórico; a Seção 3 descreve a arquitetura analisada; a Seção 4 discute resultados e melhorias; e a Seção 5 apresenta as conclusões.

2. Referencial Teórico

Um agente inteligente é uma entidade computacional autônoma capaz de perceber seu ambiente e agir sobre ele [Wooldridge and Jennings 1995]. Sistemas Multi-Agentes (SMA) estendem essa definição ao considerar múltiplos agentes interagindo em um ambiente compartilhado, onde coordenação e cooperação são essenciais [Weiss 1999, Russell and Norvig 2021]. Summers et al. [Summers et al. 2024] propõem o framework Co-ALA, que estrutura agentes de linguagem ao longo de três dimensões — memória, espaço de ação e tomada de decisão — enquanto Wang et al. [Wang et al. 2024] introduzem um framework unificado com módulos de perfil, memória, planejamento e ação.

No âmbito de frameworks multi-agentes colaborativos, Qian et al. [Qian et al. 2024] propõem o ChatDev, onde agentes LLM com papéis predefinidos colaboram iterativamente no desenvolvimento de software. Zhang et al. [Zhang et al. 2023] introduzem o CoELA, projetado para agentes corporificados com integração de LLMs. Tais exemplos demonstram o potencial da integração de LLMs com componentes cognitivos [Becker 2024], mas evidenciam limitações em estabilidade de raciocínio e coordenação, motivando a abordagem orientada por tarefas de Silva et al.

3. Arquitetura do Sistema Analisado

3.1. Visão Geral

A arquitetura proposta por Silva et al. [Silva et al. 2025] organiza-se em três camadas (Figura 1): (i) uma camada de **interação com o usuário**, através de uma interface conversacional; (ii) um **Agente Orquestrador**, responsável por distribuir tarefas e mediar a comunicação; e (iii) um conjunto de **Task-driven Agents** especializados que acessam ferramentas externas e compartilham uma **Memória Compartilhada**. Esta última funciona como um *blackboard*, persistindo dados como DataFrames, funções e objetos gerados pelos agentes.

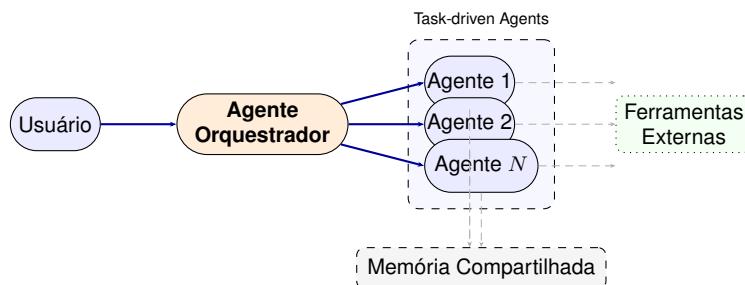


Figura 1. Visão geral da arquitetura multi-agente proposta por Silva et al.

3.2. Estrutura Cognitiva dos Agentes

Diferentemente de abordagens que agrupam agentes por comportamento comum (e.g., um agente planejador), Silva et al. adotam agentes orientados por tarefa (*task-driven*),

cada um composto por cinco módulos cognitivos interconectados (Figura 2). A **Memória Híbrida** atua como hub central, integrando: *Working Memory* (curto prazo, contexto da iteração atual), *Memória Semântica* (longo prazo, baseada em RAG [Lewis et al. 2021] com OpenSearch) e *Memória Procedural* (histórico de interações com o LLM). O módulo de **Planejamento** encapsula a tomada de decisão. A **Execução** transforma planos em ações concretas via ferramentas externas. A **Percepção** enriquece o conhecimento do agente a partir do ambiente e da Memória Compartilhada. O **Raciocínio** gerencia as interações com o LLM e o código determinístico do agente.

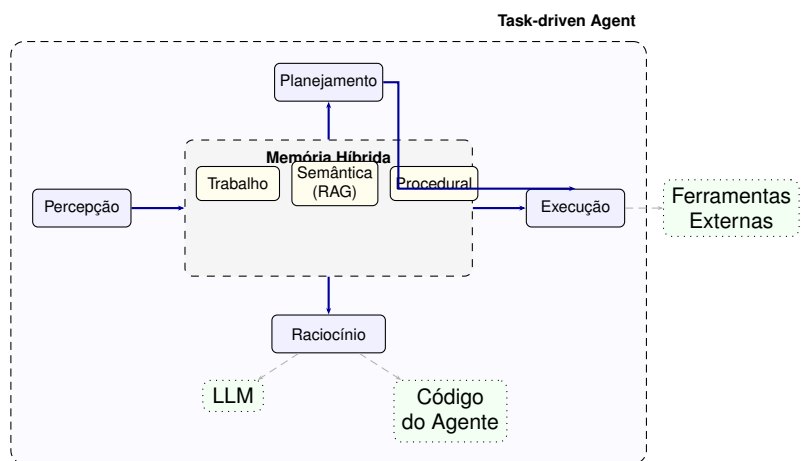


Figura 2. Estrutura interna de um agente cognitivo (*Task-driven Agent*).

A implementação utiliza Python com LangGraph como framework de orquestração, GPT-4o como LLM base e OpenSearch para persistência de memória, com embeddings `ada-002` para o sistema RAG.

3.3. Aplicação Financeira

A viabilidade da arquitetura foi demonstrada em um cenário financeiro com três agentes (Figura 3): o **Agente Moderador** (MA), que atua como orquestrador; o **Agente Financeiro** (AF), que coleta dados de mercado via API *yfinance*; e o **Agente de Código** (AC), que gera visualizações com *Plotly*. A coordenação segue o paradigma conversacional *Report* [Becker 2024]: cada agente reporta seus resultados ao Moderador, que decide o próximo passo. A Memória Compartilhada armazena progressivamente os artefatos gerados — DataFrames de preços, funções Python e gráficos — permitindo que agentes posteriores reutilizem resultados anteriores.




Figura 3. Fluxo de comunicação no paradigma *Report* — aplicação financeira.

4. Resultados e Discussões

A arquitetura apresenta contribuições relevantes. A abordagem de agentes orientados por tarefa promove modularidade e escalabilidade, permitindo a adição de novos agentes sem modificar a estrutura existente. A Memória Compartilhada funciona como um *blackboard* eficaz, facilitando a troca de informações sem comunicação direta entre agentes. A integração de múltiplos tipos de memória — Working, Semantic e Procedural — alinha-se com o framework CoALA [Sumers et al. 2024], e o paradigma conversacional flexível permite diferentes configurações de coordenação.

Apesar dos avanços, identificam-se limitações importantes. A avaliação foi conduzida com apenas um cenário de aplicação, limitando a generalização. A Memória Compartilhada não possui mecanismos de resolução de conflitos ou controle de consistência. A comunicação entre agentes ocorre exclusivamente via Orquestrador, sem possibilidade de interação direta. Além disso, a dependência exclusiva do GPT-4o restringe a portabilidade. Como melhorias, propõem-se: (i) a incorporação de *Knowledge Graphs* para enriquecer a Memória Semântica; (ii) protocolos de comunicação direta entre agentes; (iii) estudos ablativos para avaliar a contribuição individual de cada módulo; e (iv) avaliação com múltiplos cenários e *benchmarks* padronizados.

5. Conclusões

Este trabalho analisou criticamente a arquitetura multi-agente cognitiva de Silva et al. [Silva et al. 2025], identificando como contribuições-chave a modularidade proporcionada por agentes orientados por tarefa e a integração de múltiplos tipos de memória inspirada em arquiteturas cognitivas [Sumers et al. 2024]. As limitações apontadas — avaliação restrita, ausência de resolução de conflitos na memória compartilhada e comunicação exclusivamente mediada — indicam direções de pesquisa futuras, como a integração de *Knowledge Graphs*, o desenvolvimento de *benchmarks* para arquiteturas multi-agentes cognitivas e a investigação de paradigmas alternativos de comunicação entre agentes.

Referências

- Becker, J. (2024). Multi-agent large language models for conversational task-solving. *arXiv preprint arXiv:2410.22932*.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., tau Yih, W., Rocktäschel, T., Riedel, S., and Kiela, D. (2021). Retrieval-augmented generation for knowledge-intensive NLP tasks. *arXiv preprint arXiv:2005.11401*.
- Qian, C., Liu, W., Liu, H., Chen, N., Dang, Y., Li, J., Yang, C., Chen, W., Su, Y., Cong, X., et al. (2024). ChatDev: Communicative agents for software development. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 15174–15186.
- Russell, S. and Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. Pearson, 4th edition.
- Silva, E., Santos, F. A., Thompson, P., and dos Reis, J. C. (2025). LLM-powered conversational multi-agent cognitive system for collaborative task solving. In *19th Workshop-School on Agents, Environments, and Applications (WESAAC)*, pages 59–70.

- Sumers, T. R., Yao, S., Narasimhan, K., and Griffiths, T. L. (2024). Cognitive architectures for language agents. *Transactions on Machine Learning Research*. Survey Certification.
- Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., et al. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6):186345.
- Weiss, G. (1999). *Multiagent Systems: A Modern Approach to Distributed Artificial Intelligence*. MIT Press.
- Wooldridge, M. and Jennings, N. R. (1995). Intelligent agents: Theory and practice. *The Knowledge Engineering Review*, 10(2):115–152.
- Zhang, H., Du, W., Shan, W., Zhou, J., Du, Q., Du, Y., Tenenbaum, J. B., Tianmin, S., and Chuang, G. (2023). Building cooperative embodied agents modularly with large language models. *arXiv preprint arXiv:2307.02485*.