

Sistemas Multi-Agentes Cognitivos Baseados em LLMs para Resolução Colaborativa de Tarefas

Jean Reinholt¹

¹Centro de Desenvolvimento Tecnológico (CDTec)
Universidade Federal de Pelotas (UFPel)
Pelotas – RS – Brasil

jreinholt@inf.ufpel.edu.br

Resumo. Sistemas multi-agentes baseados em Modelos de Linguagem de Grande Escala (LLMs) têm se destacado como abordagem promissora para a resolução colaborativa de problemas complexos. Este trabalho analisa a arquitetura proposta por Silva et al. (2025), que introduz um sistema multi-agente conversacional cognitivo onde um agente orquestrador distribui dinamicamente tarefas entre agentes especializados equipados com módulos cognitivos. Realizou-se uma análise crítica da arquitetura, identificando seus pontos fortes — como a modularidade e o uso de memória compartilhada — e suas limitações, incluindo desafios de escalabilidade e avaliação. Propõem-se melhorias relacionadas à gestão de memória e aos mecanismos de coordenação entre agentes.

Abstract. Multi-agent systems powered by Large Language Models (LLMs) have emerged as a promising approach for collaborative complex problem-solving. This work analyzes the architecture proposed by Silva et al. (2025), which introduces a conversational cognitive multi-agent system where an orchestrator agent dynamically distributes tasks among specialized agents equipped with cognitive modules. A critical analysis of the architecture was conducted, identifying its strengths — such as modularity and shared memory usage — and its limitations, including scalability and evaluation challenges. Improvements related to memory management and inter-agent coordination mechanisms are proposed.

1. Introdução

Arquiteturas de sistemas multi-agentes baseadas em LLMs têm emergido como abordagem poderosa para a resolução de problemas complexos, permitindo que múltiplos agentes autônomos colaborem em um ambiente compartilhado [Wang et al. 2024]. Apesar dos avanços, desafios significativos persistem: a garantia de comunicação e coordenação fluidas, a manutenção de consistência comportamental e a gestão eficaz de memória em ambientes dinâmicos permanecem como questões em aberto [Sumers et al. 2024].

Silva et al. [Silva et al. 2025] propõem uma arquitetura multi-agente na qual um agente orquestrador distribui dinamicamente tarefas entre agentes cognitivos especializados, denominados *Task-driven Agents*. O sistema utiliza memória compartilhada como mecanismo de coordenação e um paradigma conversacional flexível para comunicação entre agentes.

Este trabalho tem como objetivo analisar criticamente essa arquitetura, identificando seus pontos fortes e limitações, e propor melhorias. A Seção 2 apresenta o referencial teórico; a Seção 3 descreve a arquitetura analisada; a Seção 4 discute resultados e melhorias; e a Seção 5 apresenta as conclusões.

2. Referencial Teórico

Um agente inteligente é uma entidade computacional autônoma capaz de perceber seu ambiente e agir sobre ele [Wooldridge and Jennings 1995]. Sistemas Multi-Agentes (SMA) estendem essa definição ao considerar múltiplos agentes interagindo em um ambiente compartilhado, onde coordenação e cooperação são essenciais [Weiss 1999, Russell and Norvig 2021]. Sumers et al. [Sumers et al. 2024] propõem o framework CoALA, que estrutura agentes de linguagem ao longo de três dimensões — memória, espaço de ação e tomada de decisão — enquanto Wang et al. [Wang et al. 2024] introduzem um framework unificado com módulos de perfil, memória, planejamento e ação.

No âmbito de frameworks multi-agentes colaborativos, Qian et al. [Qian et al. 2024] propõem o ChatDev, onde agentes LLM com papéis predefinidos colaboram iterativamente no desenvolvimento de software. Zhang et al. [Zhang et al. 2023] introduzem o CoELA, projetado para agentes corporificados com integração de LLMs. Tais exemplos demonstram o potencial da integração de LLMs com componentes cognitivos [Becker 2024], mas evidenciam limitações em estabilidade de raciocínio e coordenação, motivando a abordagem orientada por tarefas de Silva et al.

3. Arquitetura do Sistema Analisado

3.1. Visão Geral

A arquitetura proposta por Silva et al. [Silva et al. 2025] organiza-se em três camadas (Figura 1): (i) uma camada de **interação com o usuário**, através de uma interface conversacional; (ii) um **Agente Orquestrador**, responsável por distribuir tarefas e mediar a comunicação; e (iii) um conjunto de **Task-driven Agents** especializados que acessam ferramentas externas e compartilham uma **Memória Compartilhada**. Esta última funciona como um *blackboard*, persistindo dados como DataFrames, funções e objetos gerados pelos agentes.




Figura 1. Visão geral da arquitetura multi-agente proposta por Silva et al.

3.2. Estrutura Cognitiva dos Agentes

Diferentemente de abordagens que agrupam agentes por comportamento comum, Silva et al. adotam agentes orientados por tarefa (*task-driven*), cada um composto por cinco

módulos cognitivos (Figura 2). A **Memória Híbrida** é o hub central, integrando três tipos: *Working Memory* (curto prazo), *Memória Semântica* (longo prazo, baseada em RAG [Lewis et al. 2021]) e *Memória Procedural* (histórico de interações com o LLM). Os módulos de **Planejamento** e **Execução** transformam decisões em ações concretas via ferramentas externas; a **Percepção** enriquece o conhecimento do agente a partir do ambiente; e o **Raciocínio** gerencia as interações com o LLM e o código determinístico.




Figura 2. Estrutura interna de um agente cognitivo (*Task-driven Agent*).

3.3. Aplicação Financeira

A viabilidade da arquitetura foi demonstrada em um cenário financeiro implementado em Python com LangGraph e GPT-4o, envolvendo três agentes (Figura 3): o **Agente Moderador** (MA), que atua como orquestrador; o **Agente Financeiro** (AF), que coleta dados via API *yfinance*; e o **Agente de Código** (AC), que gera visualizações com *Plotly*. A coordenação segue o paradigma *Report* [Becker 2024]: cada agente reporta ao Moderador, que decide o próximo passo. A Memória Compartilhada armazena progressivamente os artefatos gerados, permitindo que agentes posteriores reutilizem resultados anteriores.




Figura 3. Fluxo de comunicação no paradigma *Report* — aplicação financeira.

4. Resultados e Discussões

A arquitetura apresenta contribuições relevantes: a abordagem *task-driven* promove modularidade e escalabilidade; a Memória Compartilhada funciona como *blackboard*, facilitando a troca de informações; a integração de múltiplos tipos de memória alinha-se com o framework CoALA [Sumers et al. 2024]; e o paradigma conversacional flexível permite diferentes configurações de coordenação.

Contudo, identificam-se limitações: avaliação restrita a um único cenário, ausência de resolução de conflitos na Memória Compartilhada, comunicação exclusivamente

mediada pelo Orquestrador e dependência do GPT-4o. Como melhorias, propõem-se: (i) *Knowledge Graphs* para enriquecer a Memória Semântica; (ii) protocolos de comunicação direta entre agentes; (iii) estudos ablativos dos módulos cognitivos; e (iv) avaliação com múltiplos cenários e *benchmarks* padronizados.

5. Conclusões

Este trabalho analisou criticamente a arquitetura multi-agente cognitiva de Silva et al. [Silva et al. 2025], identificando como contribuições-chave a modularidade proporcionada por agentes orientados por tarefa e a integração de múltiplos tipos de memória inspirada em arquiteturas cognitivas [Sumers et al. 2024]. As limitações apontadas — avaliação restrita, ausência de resolução de conflitos na memória compartilhada e comunicação exclusivamente mediada — indicam direções de pesquisa futuras, como a integração de *Knowledge Graphs*, o desenvolvimento de *benchmarks* para arquiteturas multi-agentes cognitivas e a investigação de paradigmas alternativos de comunicação entre agentes.

Referências

- Becker, J. (2024). Multi-agent large language models for conversational task-solving. *arXiv preprint arXiv:2410.22932*.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., tau Yih, W., Rocktäschel, T., Riedel, S., and Kiela, D. (2021). Retrieval-augmented generation for knowledge-intensive NLP tasks. *arXiv preprint arXiv:2005.11401*.
- Qian, C., Liu, W., Liu, H., Chen, N., Dang, Y., Li, J., Yang, C., Chen, W., Su, Y., Cong, X., et al. (2024). ChatDev: Communicative agents for software development. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 15174–15186.
- Russell, S. and Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. Pearson, 4th edition.
- Silva, E., Santos, F. A., Thompson, P., and dos Reis, J. C. (2025). LLM-powered conversational multi-agent cognitive system for collaborative task solving. In *19th Workshop-School on Agents, Environments, and Applications (WESAAC)*, pages 59–70.
- Sumers, T. R., Yao, S., Narasimhan, K., and Griffiths, T. L. (2024). Cognitive architectures for language agents. *Transactions on Machine Learning Research*. Survey Certification.
- Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., et al. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6):186345.
- Weiss, G. (1999). *Multiagent Systems: A Modern Approach to Distributed Artificial Intelligence*. MIT Press.
- Wooldridge, M. and Jennings, N. R. (1995). Intelligent agents: Theory and practice. *The Knowledge Engineering Review*, 10(2):115–152.
- Zhang, H., Du, W., Shan, W., Zhou, J., Du, Q., Du, Y., Tenenbaum, J. B., Tianmin, S., and Chuang, G. (2023). Building cooperative embodied agents modularly with large language models. *arXiv preprint arXiv:2307.02485*.